Statistik – Kapitel 0

Karsten Keßler

10. März 2026

Inhaltsverzeichnis

0 Einführung **1**
0.1 Einführung in die Statistik . . . 1
0.1.1 Was bedeutet Statistik? . . . 2
0.1.2 Warum brauchen wir Statistik? . . . 3
0.1.3 Warum Statistik in der Praxis unverzichtbar ist . . . 3
0.1.4 Das Problem der Variabilität . . . 3
0.1.5 Grundbegriffe . . . 4
0.1.6 Messniveaus (Skalentypen) . . . 6
0.1.7 Deskriptive vs. induktive Statistik . . . 9
0.1.8 Typischer Statistik-Workflow . . . 9
0.1.9 Übergang: Von Statistik zur Wahrscheinlichkeitsrechnung . . . 10
0.2 Kombinatorische Hilfsmittel . . . 10
0.2.1 Kombinatorik als Grundlage . . . 10
0.2.2 Urnenmodell . . . 10
0.2.3 Permutation . . . 12
0.2.4 Kombinationen . . . 16
0.2.5 Variationen . . . 21
0.2.6 Tabellarische Zusammenfassung . . . 22
0.3 Notebooks . . . 23

0 Einführung

0.1 Einführung in die Statistik

Leitfrage: Wie kommt man von den rohen Zahlen zu begründeten Aussagen und Entscheidungen?

Lernziele nach diesem Kapitel: (i) Grundlegende Begriffe der Statistik sauber verwenden (ii) Statistische Fragestellungen präzise formulieren (iii) Den Unterschied zwischen Deskription und Induktion erklären

0.1.1 Was bedeutet Statistik?

Der Begriff **Statistik** wird in der Praxis in drei typischen Bedeutungen verwendet:

Statistik als Datenmaterial

Veröffentlichte Zahlen, Tabellen oder Kennzahlen
(z. B. Umsatzstatistik, Arbeitslosenstatistik, Wahlstatistik).
→ Statistik als **Ergebnis** einer Datenerhebung.

Beispiele:

- Verkaufsstatistiken (monatliche Umsätze, Kundenzahlen)
- Produktionsstatistiken (Fehlerquoten, Ausschussrate)
- Personalstatistiken (Fluktuation, Krankenstandsquoten)
- Marktforschungsberichte (Marktanteile, Prognosen)
- Finanzberichte und Bilanzkennzahlen

Statistik als Methode

Verfahren zur **Erhebung**, **Aufbereitung**, **Darstellung** und **Analyse** von Daten:
Häufigkeitstabellen, Diagramme, Mittelwert/Varianz, Modelle, Tests.

Beispiele:

- Marktforschungsstudien und Umfrageanalyse
- Qualitätskontrolle und Prozessoptimierung
- Finanzanalyse und Prognosemodelle
- Personalentwicklung und Bedarfsplanung
- Produktentwicklung und Kundenforschung

Statistik als Wissenschaft

Mathematische Disziplin, die Modelle für **Zufall und Unsicherheit** entwickelt und untersucht, wie zuverlässig Schlussfolgerungen aus Stichproben sind.

Anwendungsbereiche:

- Wahrscheinlichkeitstheorie für Risiko- und Versicherungsmathematik
- Stochastische Prozesse für Warteschlangen und Produktionsplanung
- Bayessche Inferenz für Entscheidungsfindung
- Statistische Lerntheorie in der Marktforschung
- Information Theory und Kommunikationstheorie

Merksatz: In dieser Vorlesung steht Statistik vor allem als **Methode** und **Wissenschaft** im Vordergrund.

0.1.2 Warum brauchen wir Statistik?

In vielen realen Situationen sind Ergebnisse **nicht deterministisch** und Daten **unvollständig**:

- In der Qualitätskontrolle wird nicht jedes Teil geprüft.
- In Umfragen werden nicht alle Personen befragt.
- In Produktionsprozessen schwanken Messgrößen oder Ausfallraten.
- In der Wirtschaft variieren Nachfrage, Preise und Lieferzeiten.

Statistik liefert Werkzeuge, um

- Daten verständlich zu strukturieren,
- Zufall von Struktur zu trennen,
- Unsicherheit zu quantifizieren,
- Entscheidungen nachvollziehbar zu begründen.

Wichtig: Statistik liefert selten Gewissheit, sondern **begründete Aussagen mit Fehlerwahrscheinlichkeit**.

0.1.3 Warum Statistik in der Praxis unverzichtbar ist

Anwendungsbereich	**Typische statistische Fragen**
Qualitätskontrolle	Wie viele Teile müssen geprüft werden für ausreichende Qualitätssicherung?
Produktentwicklung	Ist die neue Version wirklich besser?
Marktforschung	Wie gut entspricht mein Produkt den Kundenbedürfnissen?
Betrugserkennung	Ist dieses Verhalten verdächtig oder normal?
Kapazitätsplanung	Wie viele Ressourcen brauchen wir für Spitzenlasten?
Marketing	Hat die Kampagne einen signifikanten Effekt?
Datenqualität	Wie gehen wir mit fehlenden oder fehlerhaften Daten um?
Leistungscontrolling	Erreichen wir die vereinbarten Ziele?
KI	Verbessert ein neues Modell die Trefferquote signifikant?
KI	Ab welchem Schwellenwert ist ein Alarm statistisch belastbar?

0.1.4 Das Problem der Variabilität

Selbst bei identischen Bedingungen variieren Messergebnisse:

Beispiel: Eine Maschine fertigt Teile mit einer Länge von 50 mm. Bei 5 Messungen an verschiedenen Teilen derselben Charge:

Messung	Länge (mm)
1	49,8
2	50,3
3	49,9
4	52,1
5	50,1

Fragen:

- Was ist die typische Länge? → *Mittelwert* (arithmetisches Mittel aller Werte), *Median* (mittlerer Wert, wenn alle sortiert sind) oder *Modalwert* (häufigster Wert)?
- Ist Messung 4 ein Ausreißer oder normal? → *Ausreißererkennung* mit *Quartilen* (Werte, die Daten in Viertel teilen: Q1=25%, Q2=50%, Q3=75%) und *Boxplots* (grafische Darstellung mit Box von Q1 bis Q3 und Ausreißern)
- Wie zuverlässig ist ein einzelner Messwert?
  → *Konfidenzintervalle* für die mittlere Länge

→ Statistik liefert die Werkzeuge, um solche Fragen systematisch zu beantworten.

0.1.5 Grundbegriffe

Statistische Einheit (Merkmalsträger)

Die **statistische Einheit** ist das Objekt, über das Daten erhoben werden (kleinste Untersuchungseinheit).

Allgemeine Beispiele: Person, Bestellung, Produkt, Bauteil, Messung

Praktische Beispiele:

Kontext	Statistische Einheit
Kundenbefragung	Ein Kunde
Produktfertigung	Ein gefertigtes Bauteil
Verkaufsanalyse	Ein Verkaufsvorgang / Eine Bestellung
Personalmanagement	Ein Arbeitnehmer / Ein Arbeitstag
Lieferkette	Eine Lieferung / Ein Transport
Marktforschung	Ein Testproband / Ein Haushalt
Finanzanalyse	Ein Geschäftstag / Ein Handelstag
Qualitätsmanagement	Ein Prüfergebnis / Eine Prüfstelle

Merkmal und Merkmalsausprägung

- **Merkmal:** Eigenschaft der Einheit (z. B. *Lieferzeit*)
- **Merkmalsausprägung:** konkret beobachteter Wert (z. B. *3,2 Tage*)

Mini-Beispiel:
Einheit = Lieferung · Merkmal = Lieferzeit · Ausprägung = 3,2 Tage

Praktisches Beispiel:

Einheit	Merkmal	Ausprägung
Bestellung	Lieferzeit	5 Tage
Bestellung	Status	Versendet
Bestellung	Bestellmenge	25 Stück
Mitarbeiter	Gehalt	3.200 €
Produkt	Fehlerrate	2,3 %
Verkaufsregion	Wachstum	12 %

Grundgesamtheit und Stichprobe

- **Grundgesamtheit:** alle relevanten Einheiten, über die eine Aussage getroffen werden soll
- **Stichprobe:** tatsächlich beobachtete Teilmenge

Beispiel:
Grundgesamtheit = alle Lieferungen eines Jahres
Stichprobe = 120 zufällig ausgewählte Lieferungen

Praktische Beispiele:

Grundgesamtheit	Stichprobe
Alle Kunden (50.000)	500 zufällig ausgewählte Kunden für Umfrage
Alle produzierten Teile eines Monats (100.000)	500 geprüfte Teile
Alle möglichen Produktvarianten	Ausgewählte Varianten für Markttest
Alle Lieferanten	Die letzten 50 Lieferungen analysieren
Alle potenziellen Käufer	Fokusgruppe mit 20 Testpersonen

Repräsentativität: Die Stichprobe soll die Grundgesamtheit möglichst gut abbilden. Verzerrungen (Bias) führen zu falschen Schlussfolgerungen.

Bias in der Marktforschung und Statistik

Typische Verzerrungen bei Datenerhebung:

Bias-Art	Beschreibung	Beispiel
Survivorship Bias (Überlebensverzerrung)	Nur „überlebende" Daten werden analysiert	Nur zufriedene Kunden geben Feedback
Selection Bias (Auswahlverzerrung)	Systematisch verzerrte Auswahl	Nur Vielkäufer werden in Umfrage befragt
Temporal Bias (Zeitverzerrung)	Zeitliche Verzerrung	Daten nur von Werktagen, nicht Wochenenden
Sampling Bias (Stichprobenverzerrung)	Nicht-repräsentative Stichprobe	Befragung nur in einer Stadt, nicht bundesweit
Measurement Bias (Messverzerrung)	Messung beeinflusst Ergebnis	Beobachtung verändert Kundenverhalten
Algorithmic Bias (Algorithmische Verzerrung)	Trainingsdaten spiegeln bestehende Vorurteile wider	KI-Bewerbungsfilter bevorzugt männliche Kandidaten

Beispiel Algorithmic Bias (KI-Diskriminierung):

Ein ML-Modell zur Vorauswahl von Bewerbungen wird mit historischen Einstellungsdaten trainiert.
Wenn in der Vergangenheit bestimmte Gruppen (z. B. Frauen oder Personen mit nicht-deutsch klingenden Namen) seltener eingestellt wurden, lernt das Modell dieses Muster mit.

→ Ergebnis: Die KI benachteiligt diese Gruppen systematisch, obwohl das Merkmal fachlich irrelevant ist.

Beispiel Survivorship Bias (Überlebensverzerrung):

Ein Einzelhandelsunternehmen analysiert Kundenrezensionen online. Nur sehr zufriedene und sehr unzufriedene Kunden schreiben Rezensionen. Durchschnittlich zufriedene Kunden fehlen.

→ Die gemessene durchschnittliche Zufriedenheit ist **systematisch verzerrt**, weil die Meinungen der Mehrheit (zufriedene, aber nicht begeisterte Kunden) unterrepräsentiert sind.

0.1.6 Messniveaus (Skalentypen)

Das **Messniveau** bestimmt, welche statistischen Auswertungen sinnvoll und zulässig sind.

Nominalskala

- Kategorien ohne natürliche Ordnung
- Erlaubte Operationen: Gleichheit (=, neq)
- Beispiele: Farbe, Land, Produkttyp
- Auswertungen: Häufigkeiten, Modus, Balkendiagramme

Praktische Beispiele:

- Zahlungsart (Kreditkarte, EC-Karte, Banküberweisung, Bargeld)
- Bundesland (Baden-Württemberg, Bayern, Berlin, etc.)
- Produktkategorie (Elektronik, Kleidung, Lebensmittel, Möbel)
- Geschlecht (männlich, weiblich, divers)
- Fehlertyp (Material, Verarbeitung, Design, Verpackung)
- Verkaufskanal (Einzelhandel, Online, Großhandel, Direktvertrieb)

Ordinalskala

- Geordnete Kategorien ohne interpretierbare Abstände
- Erlaubte Operationen: Gleichheit + Ordnung ($<$, $>$, leq, geq)
- Beispiele: Schulnoten[1], Zufriedenheit (1–5), Rankings
- Auswertungen: Median, Quartile, Rangmaße
  (Mittelwert nur mit Vorsicht!)

Praktische Beispiele:

- Aufgabenpriorität (Kritisch, Hoch, Mittel, Niedrig)
- Kundenrezension (1–5 Sterne)
- Schweregrad eines Fehlers (Unbedeutend, Gering, Mittel, Schwer, Kritisch)
- Geschäftsgröße (Start-up, KMU, Mittelstand, Großunternehmen)
- Lieferantenstatus (Bronze, Silber, Gold, Platin)
- Produktreife (Alpha, Beta, Stable, Deprecated)

Achtung: Der Abstand zwischen 3 Sterne und 4 Sterne ist nicht notwendigerweise gleich dem Abstand zwischen 4 Sterne und 5 Sterne!

Metrische Skala

- Numerisch mit interpretierbaren Abständen
- Erlaubte Operationen:
  - **Intervallskala:** Addition/Subtraktion (Differenzen)
  - **Verhältnisskala:** zusätzlich Multiplikation/Division (Verhältnisse)
- Beispiele: Zeit, Gewicht, Umsatz, Temperatur
- Auswertungen: Mittelwert, Varianz/Stdabw, Korrelation, Regression

Unterscheidung:

- **Intervallskala:** Kein natürlicher Nullpunkt (z. B. Temperatur in °C, Datum/Zeitstempel)
- **Verhältnisskala:** Natürlicher Nullpunkt (0 wirklich "nichts", z. B. Zeitdauer, Gewicht, Geld, Temperatur in Kelvin)

[1] Der Notendurchschnitt wird zwar häufig berechnet, ist aber streng genommen statistisch fragwürdig, da die Abstände zwischen den Noten nicht gleichmäßig interpretierbar sind.

Praktische Beispiele:

Merkmal	Skalentyp	Begründung
Lieferzeit (Tage)	Verhältnis	0 Tage = sofort, 10 Tage = 2× so lang wie 5 Tage
Lagerbestand (Stück)	Verhältnis	0 Stück = kein Bestand
Maschinenauslastung (%)	Verhältnis	0% = keine Auslastung
Umsatz (€)	Verhältnis	0 € = kein Umsatz
Fehleranzahl	Verhältnis	0 Fehler = fehlerfrei
Zeitstempel	Intervall	Abstände interpretierbar, Nullpunkt (Datum) willkürlich
Temperatur (°C)	Intervall	0°C ≠ „keine Temperatur"

Merksatz: Nicht jede Zahl ist metrisch (z.,B. Postleitzahlen, Artikelnummern).

	Nominalskala	Ordinalskala	Intervallskala	Verhältnisskala
Beispiel	Geschlecht, Parteien, Postleitzahl, Muttersprache	Siegerlisten, Schulnoten, Ratings	Temperatur in Celsius/Fahrenheit, Datum nach christlicher Zeitrechnung, Datum nach jüdischer Zeitrechnung	Körpergröße, Reaktionszeit, Gehalt, Temperatur in Kelvin
IT-Beispiele	HTTP-Methode (GET, POST), Browser, Betriebssystem, Error-Typ	Bug-Priorität (Critical/High/Low), User-Rating (1–5), Log-Level	Timestamp (Unix-Zeit), Datum	Response-Zeit (ms), CPU-Auslastung (%), Speicherverbrauch (GB), Lines of Code
Ableitbare Interpretationen	Gleichheit oder Verschiedenheit	Gleichheit und Größer-Kleiner-Relationen (>, <)	Gleichheit, Relationen und Gleichheit/Verschiedenheit von Intervallen	Gleichheit, Relationen, Intervalle und Verhältnisse
Zulässige stat. Kennwerte	Modalwert	Modalwert, Median	Modalwert, Median, arithm. Mittel, Varianz	Modalwert, Median, arithm. Mittel, Varianz

Nicht jede Zahl ist automatisch metrisch! Beispiele:

- HTTP-Statuscodes (200, 404, 500) → Nominal
- IP-Adressen (192.168.1.1) → Nominal
- User-IDs (12345) → Nominal
- Versionsnummern (2.1.3) → Ordinal

0.1.7 Deskriptive vs. induktive Statistik

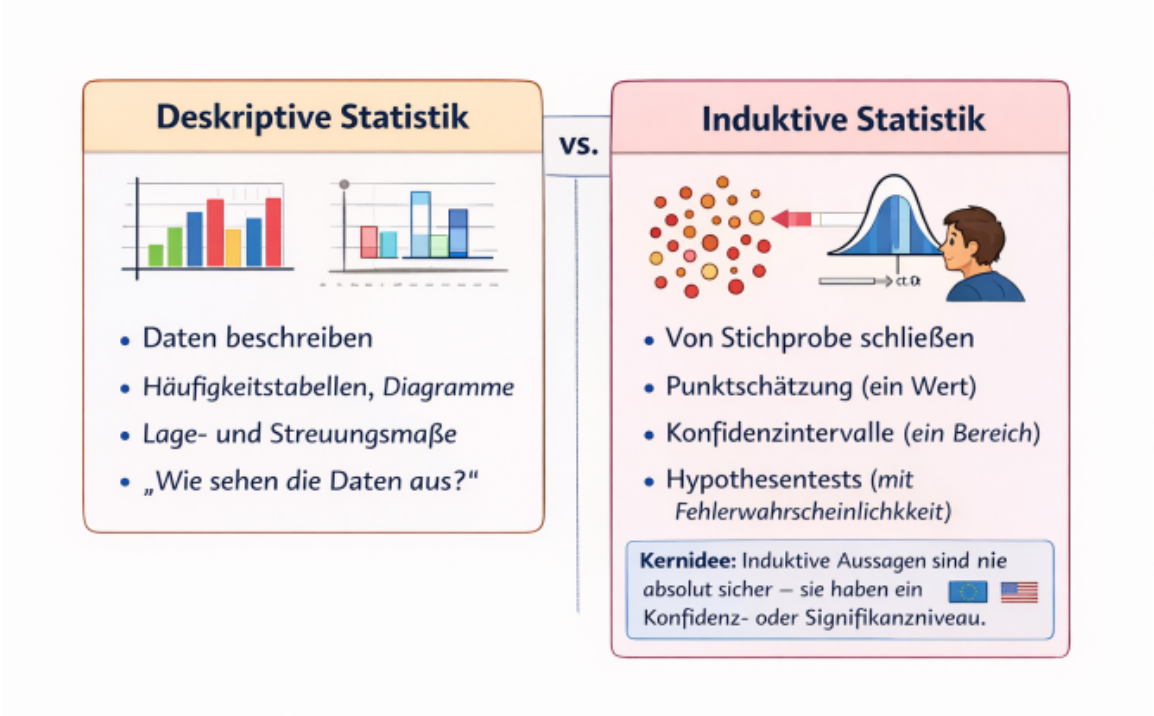

Deskriptive Statistik

Beschreibt den **vorliegenden Datensatz**:

- Häufigkeitstabellen und Diagramme
- Lage- und Streuungsmaße
- Leitfrage: *Wie sehen die Daten aus?*

Induktive Statistik (schließende Statistik)

Schließt von der **Stichprobe auf die Grundgesamtheit**:

- Punktschätzungen
- Konfidenzintervalle
- Hypothesentests

Kernidee: Induktive Aussagen sind nie absolut sicher, sie besitzen ein **Konfidenz- oder Signifikanzniveau**.

0.1.8 Typischer Statistik-Workflow

Der typische Ablauf einer statistischen Analyse folgt diesen Schritten:

1. Fragestellung präzisieren
2. Grundgesamtheit definieren
3. Stichprobenplan / Datenerhebung

4. Daten bereinigen (Fehler, Missing Values, Ausreißer)
5. Deskriptive Auswertung
6. Modellannahmen formulieren
7. Induktiv schließen
8. Interpretation im Kontext

0.1.9 Übergang: Von Statistik zur Wahrscheinlichkeitsrechnung

Viele statistische Modelle basieren auf **Zufallsexperimenten** und auf der Frage, wie viele mögliche Ergebnisse es gibt und wie wahrscheinlich diese sind.

Daher starten wir als mathematische Grundlage mit der **Wahrscheinlichkeitsrechnung**. Zuerst betrachten wir kombinatorische Zählverfahren (Permutation, Kombination, Variation), die später direkt in Wahrscheinlichkeiten übergehen.

0.2 Kombinatorische Hilfsmittel

0.2.1 Kombinatorik als Grundlage

Bevor wir mit Wahrscheinlichkeiten rechnen können, müssen wir oft wissen: Wie viele verschiedene Möglichkeiten gibt es?

Beispiel: Ein Passwort-System akzeptiert 8-stellige Passwörter aus Kleinbuchstaben. Wie viele verschiedene Passwörter sind möglich?

→ Die Kombinatorik liefert die Werkzeuge für solche Zählprobleme.

0.2.2 Urnenmodell

Ausgangssituation ist eine Urne, in der sich n Kugeln befinden. Die Kugeln können sich durch Farbe oder Nummer unterscheiden.

Zentrale Fragestellung:
Auf wie viele verschiedene Arten lassen sich Kugeln aus der Urne ziehen?

Dabei sind zwei grundlegende Entscheidungen zu treffen:

- Ziehen **mit Zurücklegen** oder **ohne Zurücklegen**
- Beachtung oder Nichtbeachtung der **Reihenfolge**

Ziehen ohne Zurücklegen

Beim Ziehen ohne Zurücklegen wird die gezogene Kugel nicht wieder in die Urne zurückgelegt. Die Anzahl der in der Urne verbleibenden Kugeln nimmt daher nach jedem Zug ab.

Abbildung 1: Ziehen ohne Zurücklegen. Nach jedem Zug wird eine Kugel entfernt, die Anzahl der verbleibenden Kugeln nimmt ab. Unterschiedliche Ziehungsreihenfolgen führen zu verschiedenen Ergebnissen.

Die möglichen Ergebnisse hängen davon ab, welche Kugeln gezogen werden und in welcher Reihenfolge die Ziehungen erfolgen.

Ziehen mit Zurücklegen

Beim Ziehen mit Zurücklegen wird die gezogene Kugel nach jedem Zug wieder in die Urne zurückgelegt. Die Anzahl der Kugeln in der Urne bleibt somit konstant.

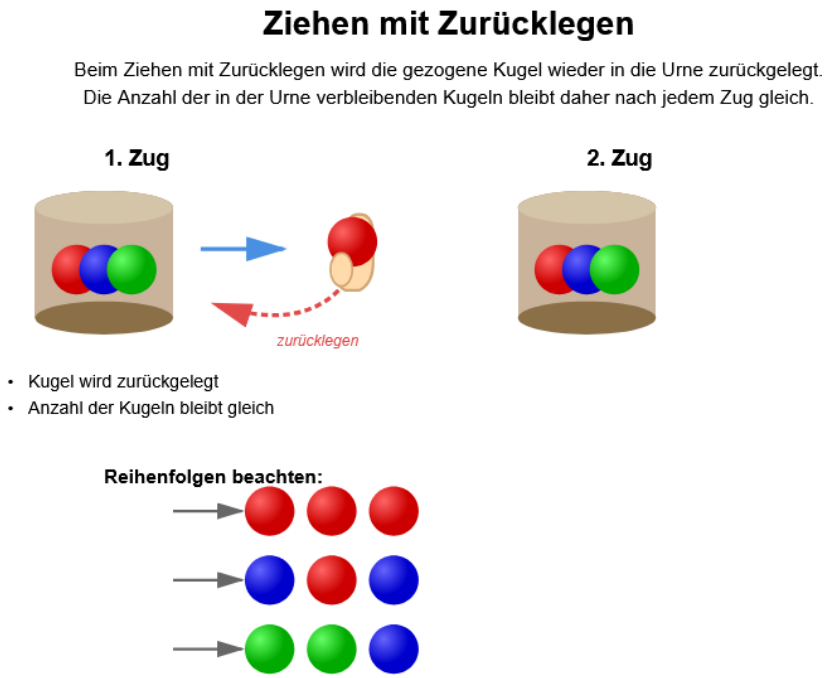

Abbildung 2: Ziehen mit Zurücklegen. Die gezogene Kugel wird nach jedem Zug zurückgelegt, sodass jede Ziehung unter identischen Bedingungen erfolgt.

Jede Ziehung erfolgt unter denselben Bedingungen wie die vorherige. Die einzelnen Ziehungen sind daher unabhängig voneinander.

Die Kombination der beiden Entscheidungen

- mit oder ohne Zurücklegen
- mit oder ohne Beachtung der Reihenfolge

führt zu den grundlegenden kombinatorischen Begriffen:

- **Permutation** (von lat. *permutare*, Anordnung aller Elemente einer Menge in verschiedenen Reihenfolgen)
- **Kombination** (von lat. *combinare*, Auswahl von Elementen, wobei die Reihenfolge keine Rolle spielt)
- **Variation** Variation (von lat. *variare*, Auswahl von Elementen, wobei die Reihenfolge eine Rolle spielt)

Diese werden in den folgenden Abschnitten systematisch eingeführt.

0.2.3 Permutation

Beim Ziehen aller n Kugeln aus der Urne, wobei **jede Kugel genau einmal gezogen** wird und **die Reihenfolge der Ziehungen beachtet wird**, spricht man von einer **Permutation**.

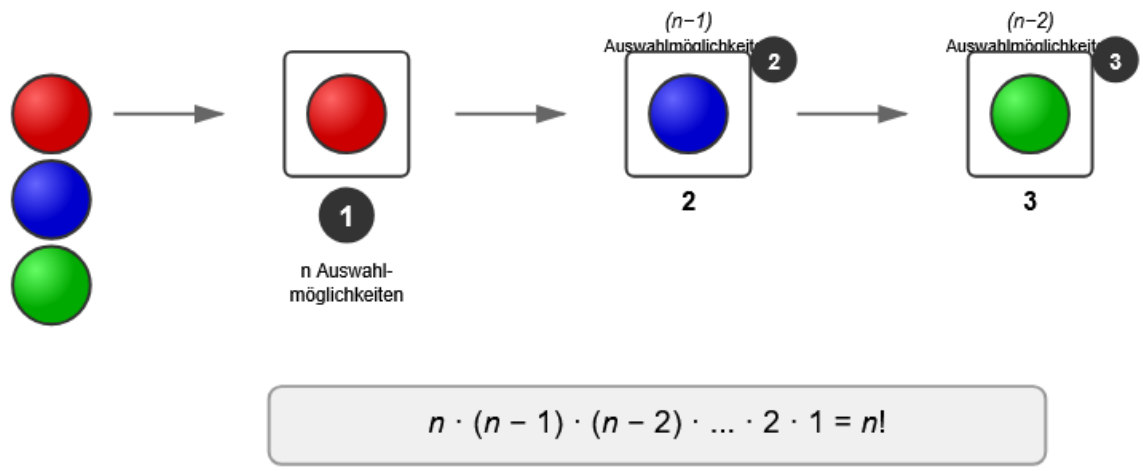

Zur Veranschaulichung betrachten wir eine Urne mit drei verschiedenfarbigen Kugeln.

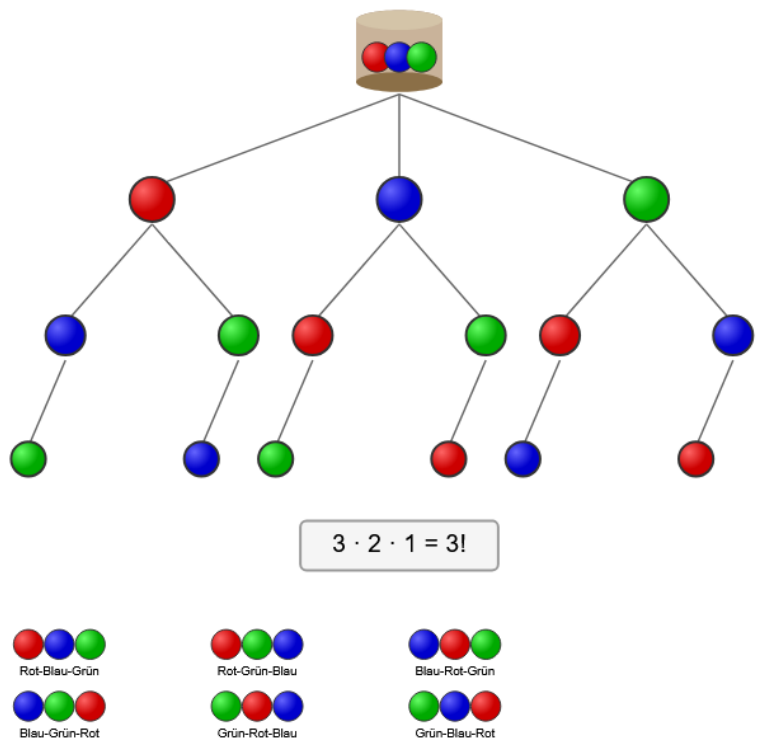

Abbildung 3: Systematische Aufzählung der möglichen Ziehungsfolgen bei drei Kugeln. Jede unterschiedliche Reihenfolge stellt eine eigene Permutation dar.

Im ersten Zug stehen drei (n) Kugeln zur Auswahl, im zweiten Zug noch zwei (n-1), im dritten Zug nur noch eine Kugel (n-2). Da jede Wahl für Position 1 mit jeder Wahl für Position 2 kombiniert werden kann (und jede dieser Kombinationen wieder mit jeder Wahl für Position 3), multipliziert man die Möglichkeiten.

Damit ergibt sich für die Anzahl der möglichen Ziehungsfolgen:

$$3 \cdot 2 \cdot 1 = 3!$$

Allgemein gilt für n verschiedene Kugeln:

$$P(n) = n \cdot (n-1) \cdot (n-2) \cdot ... \cdot 2 \cdot 1 = n!$$

Die Schreibweise $n!$ bezeichnet die **Fakultät** von n.

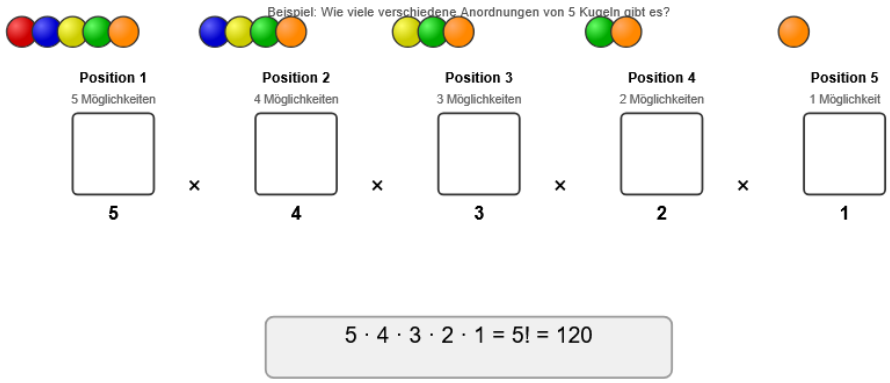

Abbildung 4: Permutation von 5 verschiedenen Kugeln. Jede Kugel wird genau einer Position zugeordnet. Die Anzahl aller möglichen Anordnungen beträgt $5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 5! = 120$.

Anwendungsbeispiel:

Ein Unternehmen plant eine Vortragsreihe mit 4 Referenten:
Schmidt, Meyer, Müller, König

Wie viele verschiedene Reihenfolgen sind möglich?

$$P(4) = 4! = 24$$

Permutation mit gleichen Elementen

Sind nicht alle Kugeln verschieden, so verringert sich die Anzahl der unterscheidbaren Permutationen.

Befinden sich unter den n Kugeln n_1 identische Kugeln, so ergibt sich:

$$P(n; n_1) = \frac{n!}{n_1!}$$

Sind mehrere Gruppen identischer Kugeln vorhanden, z. B. $n_1, n_2, ldots, n_k$, so gilt:

$$P(n; n_1, n_2, ldots, n_k) = \frac{n!}{n_1!, n_2! \cdots n_k!}, \qquad n_1 + n_2 + \cdots + n_k = n$$

Warum Division?

Das Grundprinzip der Aufteilung: Wenn N Objekte in gleich große Gruppen aufgeteilt werden, wobei jede Gruppe genau k Objekte enthält, dann beträgt die Anzahl der Gruppen:

$$\text{Anzahl Gruppen} = \frac{N}{k}$$

Beispiel: 24 Studierende sollen in 4er-Gruppen aufgeteilt werden.
Anzahl der Gruppen: $\frac{24}{4} = 6$ Gruppen (da $24 = 4 * 6$).

Bei Permutationen mit Wiederholung gilt: Die $n!$ Anordnungen (wenn alle verschieden wären) lassen sich in Gruppen zu je $n_1!$ Anordnungen einteilen, die identisch aussehen. Die Anzahl der unterscheidbaren Anordnungen entspricht der Anzahl dieser Gruppen.

Weiteres Beispiel: 5 Kugeln (2 rot, 3 andere: B, G, Y)

Fall 1: Kugeln unterscheidbar (R und R)

```
R  R  B G Y    ← Anordnung 1
R  R  B G Y    ← Anordnung 2
```

→ 2 verschiedene Anordnungen

Fall 2: Kugeln identisch (beide R)

```
R R B G Y      ← sieht genauso aus
R R B G Y      ← sieht genauso aus (kein Unterschied)
```

→ Sind visuell identisch!

Das Kernproblem:

- Die 2 roten Kugeln werden durch $2! = 2$ unterschiedliche Positionen erzeugt
- Diese erzeugen aber **keine** visuellen Unterschiede
- Jede unterscheidbare Anordnung wird doppelt gezählt

Lösung: Division durch 2!:

$$P(5; 2) = \frac{5!}{2!} = \frac{120}{2} = 60 \text{ unterscheidbare Anordnungen}$$

Abbildung 5 illustriert, dass durch identische Kugeln mehrere Ziehungsfolgen nicht unterscheidbar sind.

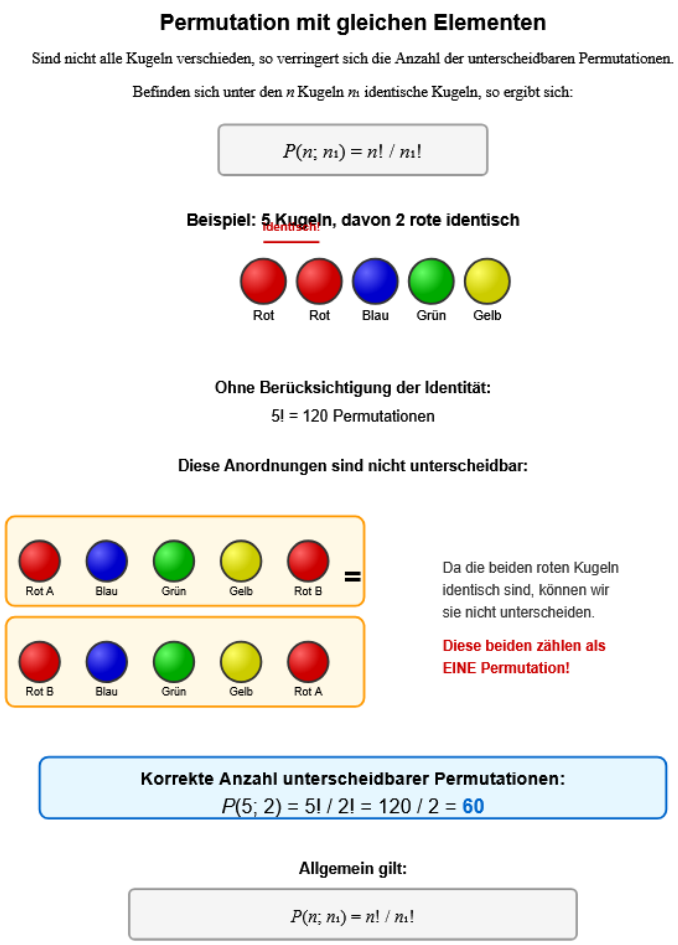

Anwendungsbeispiel:

Ein Modedesigner entwirft ein Muster aus 8 Elementen: 3× rote Punkte, 3× blaue Punkte, 2× grüne Punkte.

Wie viele unterscheidbare Muster sind möglich?

$$P(8; 3, 3, 2) = \frac{8!}{3! \cdot 3! \cdot 2!} = \frac{40,320}{6 \cdot 6 \cdot 2} = 560$$

0.2.4 Kombinationen

Werden aus einer Urne mit n Kugeln k **Kugeln gezogen**, wobei

- **nicht zurückgelegt** wird und
- **die Reihenfolge keine Rolle spielt**,

so spricht man von einer **Kombination**.

Herleitung: Warum Division?

Bei Kombinationen dividiert man, weil die **Reihenfolge keine Rolle** spielt. Dadurch werden viele

unterschiedliche Anordnungen zu einer einzigen Kombination zusammengefasst.

Zur Herleitung betrachten man eine Darstellung mit k Einsen („Kugel gezogen") und $(n-k)$ Nullen („Kugel nicht gezogen"). Die Anzahl der möglichen Anordnungen dieser Symbole entspricht der Anzahl der Kombinationen.

Da Vertauschungen der Einsen untereinander sowie der Nullen untereinander keine neuen Kombinationen erzeugen, erhält man:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Die Schreibweise $\binom{n}{k}$ heißt **Binomialkoeffizient**.

Die Bedeutung von k! und (n-k)!

Die Division durch $k!$ und $(n-k)!$ in der Kombinationsformel hat eine präzise Bedeutung:

$$\binom{n}{k} = \frac{n!}{k! \cdot (n-k)!} = \frac{\text{Alle Permutationen}}{\text{Permutationen pro Auswahl}}$$

Die $k!$ Permutationen der **gewählten Objekte** untereinander erzeugen die gleiche Auswahl.
Die $(n-k)!$ Permutationen der **nicht gewählten Objekte** untereinander erzeugen die gleiche Auswahl.

Man dividiert durch die „**internen Umordnungen**", die die Auswahl nicht verändern, sondern nur die Reihenfolge.

Merksatz: Eine Kombination ist eine **Auswahl von Objekten**, bei der die Reihenfolge egal ist. Man dividiert durch $k!$ und $(n-k)!$, um alle Permutationen mit der gleichen Auswahl zu einer einzigen Kombination zusammenzufassen.

Konkretes Beispiel: Warum dividieren man durch $k!$?

Betrachten wir 5 Kugeln (A, B, C, D, E) und wählen 3 (z.B. A, B, C):

Wenn die Reihenfolge zählen würde (Variation):

```
A B C    ← unterschiedlich
A C B    ← unterschiedlich
B A C    ← unterschiedlich
B C A    ← unterschiedlich
C A B    ← unterschiedlich
C B A    ← unterschiedlich
```

Das sind 6 verschiedene Anordnungen, also:

$$V(5;3) = 5 \cdot 4 \cdot 3 = 60 \text{ Variationen}$$

Aber die Reihenfolge zählt nicht (Kombination):

```
{A, B, C}    ← die gleiche Kombination!
{A, C, B}    ← die gleiche Kombination!
{B, A, C}    ← die gleiche Kombination!
{B, C, A}    ← die gleiche Kombination!
{C, A, B}    ← die gleiche Kombination!
{C, B, A}    ← die gleiche Kombination!
```

Alle 6 Anordnungen sind identisch!

Das Kernproblem:

- Die 3 Kugeln können auf $3! = 6$ verschiedene Arten angeordnet werden
- Aber jede dieser 6 Anordnungen stellt die **gleiche** Kombination dar
- In den 60 Variationen haben wir jede Kombination daher **6 mal gezählt**

Die Lösung – Division durch 3!:

$$\binom{5}{3} = \frac{V(5;3)}{3!} = \frac{60}{6} = 10 \text{ unterscheidbare Kombinationen}$$

Allgemein:

$$\binom{n}{k} = \frac{n!/(n-k)!}{k!} = \frac{n!}{k! \cdot (n-k)!}$$

Wir dividieren durch $k!$, weil jede k-elementige Menge auf genau $k!$ verschiedene Weisen angeordnet werden kann, aber alle diese Anordnungen sind die gleiche Kombination.

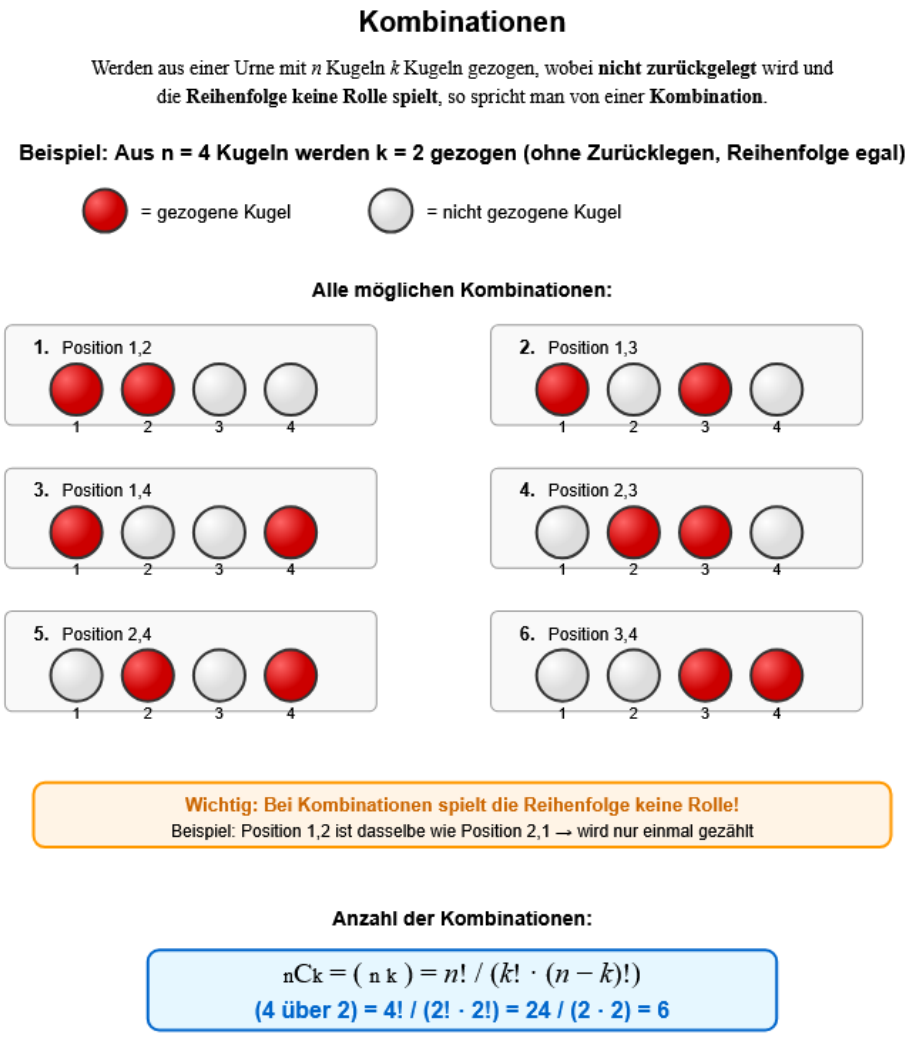

Abbildung 6: Kombinationen. Beim Ziehen ohne Zurücklegen und ohne Beachtung der Reihenfolge werden unterschiedliche Ziehungsfolgen als gleiches Ergebnis gezählt.

Anwendungsbeispiel:

Für eine Fokusgruppe sollen aus 10 Kandidaten genau 3 ausgewählt werden, um sie zusammen zu interviewen. Die Reihenfolge spielt keine Rolle.

Wie viele verschiedene Gruppen-Kombinationen gibt es?

$$\binom{10}{3} = \frac{10!}{3! \cdot 7!} = \frac{10 \cdot 9 \cdot 8}{3 \cdot 2 \cdot 1} = 120$$

Kombinationen mit Wiederholung

Werden aus n Kugeln k **Kugeln gezogen**, wobei

- **mit Zurücklegen** gezogen wird und

- **die Reihenfolge keine Rolle spielt**,

so spricht man von einer **Kombination mit Wiederholung** (auch *Kombination mit Zurücklegen* genannt).

Herleitung

Bei Kombinationen mit Wiederholung kann jede Farbe mehrfach vorkommen. Um die Formel herzuleiten, verwenden wir einen Trick: Wir stellen jede Auswahl als Folge von Sternen (*) und Trennstrichen (|) dar.

Warum verwenden wir diesen Trick?

Der Trick mit den Trennstrichen löst ein grundlegendes Problem: **Wie zählt man Auswahlen, bei denen die Reihenfolge egal ist UND Wiederholungen erlaubt sind?**

Wenn wir direkt zählen wollten, müssten wir für jede Farbe festlegen, wie oft sie vorkommt. Bei 3 Farben und 4 Kugeln gibt es unübersichtlich viele Möglichkeiten (Rot: 4×/Blau: 0×/Grün: 0×, oder Rot: 3×/Blau: 1×/Grün: 0×, oder …).

Die Lösung: Stars and Bars

Der Trick transformiert das Problem in etwas Einfaches: **"Auf wie viele Arten kann ich k Sterne und $(n-1)$ Trennstriche anordnen?"**

Warum funktioniert das?

1. **Die k Sterne** repräsentieren die k Kugeln, die wir ziehen
2. **Die $(n-1)$ Trennstriche** teilen die Sterne in n Gruppen (eine pro Farbe)
3. **Jede Anordnung** entspricht GENAU einer Auswahl mit Wiederholung

Beispiel: Aus 3 Farben (Rot, Blau, Grün) wollen wir 4 Kugeln wählen (mit Zurücklegen).

Drei mögliche Auswahlen:

$\star\ \star\ \star\ \star\ |\ |\quad \rightarrow \quad$ 4× Rot 0× Blau 0× Grün

$\star\ |\ \star\ \star\ |\ \star\quad \rightarrow \quad$ 1× Rot 2× Blau 1× Grün

$|\ \star\ \star\ \star\ |\ \star\quad \rightarrow \quad$ 0× Rot 3× Blau 1× Grün

Für n verschiedene Farben und k Ziehungen brauchen wir:

- k Sterne (*) für die Anzahl der Kugeln
- $(n-1)$ Trennstriche (|) für die Anzahl der Farbgruppen

Insgesamt haben wir $k+(n-1)$ Objekte (Sterne + Striche). Wir müssen nur noch entscheiden, an welchen $(n-1)$ Positionen die Trennstriche stehen. Das ist eine Kombination ohne Wiederholung:

$$K_w(n;k) = \binom{n+k-1}{k} = \binom{n+k-1}{n-1} = \frac{(n+k-1)!}{k! \cdot (n-1)!}$$

Anwendungsbeispiel 1: Getränkeauswahl

Ein Café bietet 5 verschiedene Getränkesorten an. Ein Team von 8 Personen bestellt zusammen, und jede Person kann ein Getränk wählen. Wie viele unterschiedliche Bestellkombinationen sind möglich? (Die Reihenfolge spielt keine Rolle, nur die Menge der Getränke.)

$$K_w(5;8) = \binom{5+8-1}{8} = \binom{12}{8} = \binom{12}{4} = \frac{12!}{8! \cdot 4!} = \frac{12 \cdot 11 \cdot 10 \cdot 9}{4 \cdot 3 \cdot 2 \cdot 1} = 495$$

Es gibt **495 verschiedene Bestellkombinationen**.

Anwendungsbeispiel 2: Münzverteilung

Ein Unternehmen möchte 10 Euro in 5 verschiedenen Währungen aufteilen (mehrere Münzen pro Währung sind möglich). Wie viele verschiedene Aufteilungsmöglichkeiten gibt es?

$$K_w(5;10) = \binom{5+10-1}{10} = \binom{14}{10} = \binom{14}{4} = 1001$$

Es gibt **1001 verschiedene Aufteilungsmöglichkeiten**.

Unterschied: Mit vs. Ohne Wiederholung

Merkmal	**Ohne Wiederholung**	**Mit Wiederholung**
Jedes Element	max. 1× auswählbar	beliebig oft auswählbar
Formel	$\binom{n}{k}$	$\binom{n+k-1}{k}$
Bedingung	$k \leq n$ erforderlich	k kann größer als n sein
Beispiel: Wähle 2 aus {A, B, C}	{A,B}, {A,C}, {B,C} = 3 Möglichkeiten	{A,A}, {A,B}, {A,C}, {B,B}, {B,C}, {C,C} = 6 Möglichkeiten

Merksatz: Kombinationen **mit Wiederholung** erlauben, dass dasselbe Element mehrfach gewählt wird. Dies ist essentiell bei Problemen, wo wir k Objekte aus n Kategorien auswählen, aber eine Kategorie mehrfach vertreten sein kann.

0.2.5 Variationen

Werden aus n Kugeln k **Kugeln gezogen**, wobei

- **die Reihenfolge berücksichtigt wird**,
  so spricht man von einer **Variation**.

Variation ohne Wiederholung (auch k-Permutation genannt)

Beim Ziehen **ohne Zurücklegen** ergibt sich:

$$V(n;k) = \frac{n!}{(n-k)!}$$

Hinweis: Die **Permutation** ist ein Spezialfall der Variation ohne Wiederholung, nämlich für (k=n):

$$V(n;n) = \frac{n!}{(n-n)!} = \frac{n!}{0!} = n!$$

Anwendungsbeispiel:

Ein Unternehmen vergibt Positionen auf dem Kundenpodium: Gold, Silber, Bronze. Es gibt 100 potenzielle Top-Kunden. Wie viele verschiedene Podium-Besetzungen sind möglich?

$$V(100;3) = \frac{100!}{97!} = 100 \cdot 99 \cdot 98 = 970{,}200$$

Variation mit Wiederholung

Beim Ziehen **mit Zurücklegen** stehen bei jeder Ziehung n Möglichkeiten zur Verfügung. Für k Ziehungen ergibt sich daher:

$$V_w(n;k) = n^k$$

(Immer n Möglichkeiten n n n … n k-mal multipliziert)

Anwendungsbeispiel:

Ein Sicherheitssystem verlangt einen 8-stelligen PIN mit Ziffern (0–9). Wie viele verschiedene PINs sind möglich?

$$V_w(10;8) = 10^8 = 100,000,000$$

Das sind 100 Millionen Möglichkeiten.

0.2.6 Tabellarische Zusammenfassung

Die wichtigsten kombinatorischen Begriffe lassen sich wie folgt zusammenfassen:

Auswahlart	**ohne Wiederholung**	**mit Wiederholung**
Kombination (Reihenfolge egal)	$\binom{n}{k}$	$\binom{n+k-1}{k}$
Variation (Reihenfolge wichtig)	$\frac{n!}{(n-k)!}$	n^k

Hinweis: **Permutation** ist der Spezialfall der Variation ohne Wiederholung für (k=n): (P(n)=V(n;n)=n!).

0.3 Notebooks

Kapitel 0

Einführung
https://colab.research.google.com/github/karkessler/dhbw-statistik/blob/main/Notebooks/Kapitel_0_Einfuehrung.ipynb

Kombinatorik
https://colab.research.google.com/github/karkessler/dhbw-statistik/blob/main/Notebooks/Kapitel_0_Kombinatorik.ipynb

Skalentypen
https://colab.research.google.com/github/karkessler/dhbw-statistik/blob/main/Notebooks/Kapitel_0_Grundbegriffe_Skalentypen.ipynb